



# 南京大學

## 課程項目報告

學院 智能科学与技术学院

专业 智能科学与技术

课程 计算生物学

题目 小样本条件下 RNA 剪接位点  
识别：多尺度上下文分析与异  
常剪接变异效应预测

学生姓名 王辰崧, 孙洪涛, 汤志远, 林锦程

# 南京大学计算生物学课程项目报告中文摘要

**题目：**小样本条件下 RNA 剪接位点识别：多尺度上下文分析与异常剪接变异效应预测

**学院：**智能科学与技术学院

**专业：**智能科学与技术

**本科生姓名：**王辰崧, 孙洪涛, 汤志远, 林锦程

**指导教师（姓名、职称）：**王博岩

**摘要：**

RNA 剪接是连接基因组序列、转录本结构与功能变异的重要分子过程。经典剪接位点通常包含 donor 侧的 GT 和 acceptor 侧的 AG 等局部共识序列，但是，真实剪接调控并不等价于对短 motif 的简单匹配：真实基因组中存在大量携带 GT/AG 却不被注释为剪接位点的诱饵序列，近剪接位点单核苷酸变异也可能改变剪接信号。围绕这一问题，本文基于 GRCh38、GENCODE v49 和 ClinVar 构建了一个小规模但真实的计算生物学 benchmark：首先建立 donor、acceptor 与 GT/AG hard-negative 三分类模型；随后比较不同上下文窗口下的识别性能；最后在 held-out chromosomes 上的 ClinVar pathogenic/likely pathogenic 与 benign/likely benign SNV 中评估变异效应排序，并用 exact-distance-matched 子集诊断距离混杂。结果表明，真实 GT/AG hard-negative 是有效压力测试；在 ClinVar 小样本上，RNA-FM frozen encoder + MLP 取得最高 AUROC/AUPRC，但 distance-matched 结果明显下降，说明近剪接距离仍是重要混杂因素。

**关键词：**RNA 剪接；剪接位点识别；多尺度上下文；变异效应预测；可解释性

# 南京大学计算生物学课程项目报告英文摘要

THESIS: RNA Splice Site Recognition, Context Analysis, and Aberrant Splicing

Variant Effect Prediction under Small-Sample Settings

DEPARTMENT: School of Intelligence Science and Technology

SPECIALIZATION: Intelligence Science and Technology

UNDERGRADUATE: Course Project Team

MENTOR: Boyan Wang

ABSTRACT:

RNA splicing links genomic sequence, transcript structure, and functional variants. Canonical splice sites often contain donor-side GT and acceptor-side AG motifs, but real genomes also contain many motif-matched decoys. This project builds a small real benchmark from GRCh38, GENCODE v49, and ClinVar: splice-site three-class classification, multi-scale context analysis with GT/AG hard negatives, and ClinVar pathogenic-vs-benign variant effect ranking with distance-matched diagnostics. Across three random seeds, real GT/AG hard negatives remain an effective stress test that keeps the false-positive rate around 0.26–0.35 for all models. On the ClinVar subset the RNA-FM frozen encoder reaches the highest AUROC/AUPRC, but every model drops sharply on the exact-distance-matched subset, showing that proximity to annotated splice sites is a key confounder rather than evidence of clinical-grade generalization.

KEYWORDS: RNA splicing; splice site recognition; multi-scale context; variant effect prediction; interpretability

# 目 录

|                                |     |
|--------------------------------|-----|
| 目 录                            | III |
| 第一章 引言                         | 1   |
| 1.1 相关工作                       | 1   |
| 1.2 研究问题与本文贡献                  | 1   |
| 第二章 数据与方法                      | 3   |
| 2.1 数据来源、构造与小样本设定              | 3   |
| 2.2 变异数据构造                     | 4   |
| 2.3 模型与权重边界                    | 4   |
| 2.4 训练设置与复现细节                  | 5   |
| 2.5 评估指标                       | 6   |
| 第三章 实验一：剪接位点三分类                | 7   |
| 3.1 实验设计                       | 7   |
| 3.2 结果                         | 7   |
| 3.3 小结                         | 9   |
| 第四章 实验二：多尺度上下文与困难负例            | 10  |
| 4.1 实验设计                       | 10  |
| 4.2 多尺度上下文结果                   | 10  |
| 4.3 Hard-negative 与 rare motif | 12  |
| 4.4 小结                         | 14  |
| 第五章 实验三：异常剪接变异效应预测             | 15  |
| 5.1 实验设计                       | 15  |

|                                  |           |
|----------------------------------|-----------|
| 5.2 ClinVar 排序结果 . . . . .       | 15        |
| 5.3 距离匹配诊断与分类型响应 . . . . .       | 17        |
| 5.4 可解释性分析 . . . . .             | 19        |
| 5.5 小结 . . . . .                 | 20        |
| <b>第六章 讨论 . . . . .</b>          | <b>21</b> |
| 6.1 三个实验之间的逻辑关系 . . . . .        | 21        |
| 6.2 关键现象解释 . . . . .             | 21        |
| 6.3 限制 . . . . .                 | 22        |
| <b>第七章 结论 . . . . .</b>          | <b>23</b> |
| <b>参考文献 . . . . .</b>            | <b>24</b> |
| <b>致 谢 . . . . .</b>             | <b>26</b> |
| <b>附录 A 数据、代码与结果路径 . . . . .</b> | <b>27</b> |
| A.1 数据路径 . . . . .               | 27        |
| A.2 代码路径 . . . . .               | 27        |
| A.3 结果与报告路径 . . . . .            | 27        |
| A.4 复现命令 . . . . .               | 28        |
| A.5 实验三 Top-k 补充指标 . . . . .     | 28        |

# 第一章 引言

RNA 剪接是从基因组编码到转录本功能的关键中间层，决定了前体 mRNA 中外显子与内含子的连接方式。剪接位点识别通常依赖 donor 位点附近的 GT、acceptor 位点附近的 AG，以及多聚嘧啶区、分支点和上下游调控元件等信息。

## 1.1 相关工作

经典剪接位点识别建立在对局部共识序列的统计建模之上。早期工作通过位置权重矩阵和最大熵模型刻画 donor/acceptor 附近的碱基偏好，证明剪接位点周围的短序列已携带强预测信号<sup>[1-2]</sup>；MaxEntScan 即是这一思路的代表性打分方法。

随着深度学习的发展，序列模型被进一步用于剪接预测和变异效应评估。SpliceAI 以较长的基因组上下文窗口直接预测剪接概率，并据此估计变异的剪接增益/损失<sup>[3]</sup>；Pangolin 在多物种、多组织上扩展了这一框架<sup>[4]</sup>；MMSplice 则以模块化方式对外显子、内含子和剪接区分别建模<sup>[5]</sup>。这些工具共同提示，剪接预测不应只被理解为简单的二核苷酸查找，而需要更大范围的上下文证据。

另一条路线是 RNA language model。RNA-FM、RNABERT 等模型从大规模无标注 RNA 序列中学习通用表示<sup>[6-7]</sup>，其冻结 encoder 可作为下游小样本任务的特征提取器。本文正是在小样本设定下，将上述三类思路（局部打分、序列深度模型、RNA language model 冻结表示）放入同一真实 benchmark 进行对比。

## 1.2 研究问题与本文贡献

本项目关注一个核心问题：剪接模型究竟是在学习真实基因组中的剪接上下文，还是仅仅在匹配短 motif？这一问题在变异效应预测中同样重要——一个单核苷酸变异可能破坏原有 donor 或 acceptor，也可能在非剪接区域制造新的 cryptic splice signal；若模型只能识别局部 GT/AG，它可能在 hard-negative 上产

生大量误报，也难以解释变异造成的剪接信号变化。因此，单独报告三分类准确率是不够的，更完整的分析应当包括上下文消融、困难负例、非经典 motif，以及变异 delta score 和可解释性分析。

围绕这一问题，本文组织为三个研究问题：

- RQ1: 在真实 GENCODE/GRCh38 小样本条件下，模型能否区分 donor、acceptor 与 GT/AG hard-negative?
- RQ2: 真实上下文窗口长度是否影响模型拒绝 motif-matched negative 的能力?
- RQ3: 剪接识别信号能否转化为真实 ClinVar pathogenic-vs-benign 变异效应排序?

本文的主要贡献包括：

- 基于 GRCh38、GENCODE v49 与 ClinVar，构造了一个染色体 holdout、gene 互斥的真实小样本剪接 benchmark，其负例全部为 GT/AG motif-matched hard-negative;
- 在多尺度上下文与困难负例下，系统比较 CNN、RNA-FM 与 RNABERT 冻结表示，并指出 hard-negative FPR 比总体 Macro-F1 更能揭示 motif 依赖;
- 在真实 ClinVar 排序任务中引入 exact-distance-matched 子集作为去混杂诊断，量化“近剪接距离”这一捷径对各模型与外部工具的影响;
- 对可训练模型报告 42/43/44 三个随机种子的统计量，并明确标注本文不能支持的结论边界。

实验一回答 RQ1。实验二主要通过多尺度上下文和 GT/AG hard-negative 回答 RQ2，rare motif 只作为补充 synthetic stress test。实验三通过真实 ClinVar SNV、distance-matched 诊断和解释性图件回答 RQ3。

## 第二章 数据与方法

### 2.1 数据来源、构造与小样本设定

项目主实验使用真实 GRCh38/GENCODE v49<sup>[8]</sup> splice-site benchmark, 而不是 synthetic 主数据集。输入资源包括 data/raw/genome.fa、data/raw/gencode.gtf 和 ClinVar VCF; reports/data\_qc.md 记录了 GRCh38、GENCODE v49、Ensembl 115、ClinVar fileDate 2026-05-30、随机种子 42 和构建命令。

真实 splice-site 数据由 src/data/build\_splice\_site\_dataset.py 生成。donor 定义为 intron 5' boundary, acceptor 定义为 intron 3' boundary; 负链转录本先按 transcript orientation 反向互补。positive 位点经过 canonical GT/AG 过滤。non-splice 类不是随机 easy negative, 而是在真实基因组中抽取的不落在 GTF 注释剪接位点上的 GT/AG motif-matched decoy, 因此全部属于 hard-negative。

全量采样比例为 donor / acceptor / hard-negative = 1000 / 1000 / 1000。主 split 采用 chromosome holdout: chr1–chr16 为 train, chr17–chr18 为 valid, chr19–chr22 与 chrX 为 test。QC 检查显示 train/valid/test 的 sample id、chromosome 与 gene id 互斥。

本文用 pm $N$  记号表示以中心位点为中心、左右各  $N$  bp (总长  $2N + 1$  bp) 的序列窗口。主实验默认使用 pm200, 即中心位点左右各 200 bp、总长 401 bp; 实验二额外使用 pm50、pm100、pm400。表 2-1 给出 pm200 split 规模。

表 2-1 真实 GENCODE/GRCh38 splice-site benchmark split

| split | rows | donor | acceptor | non-splice | length | hard-negative |
|-------|------|-------|----------|------------|--------|---------------|
| train | 2339 | 792   | 786      | 761        | 401    | 761           |
| valid | 230  | 79    | 67       | 84         | 401    | 84            |
| test  | 431  | 129   | 147      | 155        | 401    | 155           |

data/shared/processed/ 下同时保存 pm50、pm100、pm200、pm400 四个窗



口版本，四个窗口共用同一批 `sample_id -> split`，用于实验二的多尺度上下文分析。真实主 benchmark 没有 easy negative；easy negative 仅属于补充 synthetic control，不作为主结果。

## 2.2 变异数据构造

实验三使用 `src/data/build_clinvar_variant_dataset.py` 构造真实 ClinVar<sup>[9]</sup> SNV benchmark。positive 为 pathogenic / likely pathogenic 且 splice-related 或 near-splice 的记录；negative 为 benign / likely benign 且 near-splice 的记录。所有变异限制为 SNV，REF 与 GRCh38 校验，负链 REF/ALT 转为 transcript orientation；target class 由最近 donor/acceptor 决定。

`data/experiment_3/clinvar_splicing_variants.csv` 包含 500 条变异，其中 splice-altering 250 条、neutral 250 条；ClinVar 变异限制在 held-out test chromosomes，并排除实验一/二已经采样的 genes。QC 显示 pathogenic/splice-altering 变异距离注释剪接位点更近：median distance 为 9.5 bp，而 neutral 为 17 bp；distance-only baseline 在 full ClinVar 上达到 AUROC 0.6475、AUPRC 0.6917。因此，本文同时导出 exact-distance-matched 子集 `data/experiment_3/clinvar_splicing_variants_distance_matched.csv`，包含 326 条变异，正负样本 163/163，distance-only AUROC/AUPRC 均为 0.5。

## 2.3 模型与权重边界

实验一和实验二报告 CNN baseline、RNA-FM frozen encoder + MLP 和 RNABERT frozen encoder + MLP；实验三在这三类模型之外，进一步接入 SpliceAI、Pangolin、MMSplice 与 MaxEntScan 的真实工具推理结果。外部剪接工具通过 `scripts/run_real_external_tools.py` 与 `scripts/run_real_pangolin_sequence.py` 计算 WT/Mut 成对 delta 分数，只用于实验三的变异效应排序，不参与实验一和实验二的三分类训练。

表 2-2 模型名称、实际 backend 与结论边界

| 本文报告名称                       | 当前项目实际 backend                                                                               | 结论边界                     |
|------------------------------|----------------------------------------------------------------------------------------------|--------------------------|
| CNN baseline                 | PyTorch Conv1D, 以 one-hot 序列为输入, 用于代表局部 motif classifier                                     | 可作为本项目局部 motif 基线        |
| RNA-FM frozen encoder + MLP  | models/hf/rnafm/ 中的 RNA-FM 权重, 冻结 encoder 后抽取 pooled embedding, 并接 LogisticRegression 分类器    | 属于本地权重 frozen encoder 运行 |
| RNABERT frozen encoder + MLP | models/hf/rnabert/ 中的 RNABERT 权重, 冻结 encoder 后抽取 pooled embedding, 并接 LogisticRegression 分类器 | 属于本地权重 frozen encoder 运行 |

需要特别说明的是, 名称中的“+ MLP”为沿用的历史标签, 其实际分类头是 scikit-learn 的 LogisticRegression (线性分类器, 无隐藏层), 并非多层感知机; 本文保留该名称仅为与图件、结果表中的字段保持一致。本文所有结论均限定在当前小样本 benchmark、本地权重 frozen encoder 和上述边界内。

## 2.4 训练设置与复现细节

所有可训练模型使用固定随机种子 42。实验一的 CNN baseline 使用 PyTorch Conv1D: 三个卷积分支的 kernel size 分别为 3、5、9; 每个分支包含 Conv1D、BatchNorm、ReLU、第二层 Conv1D、BatchNorm、ReLU 和 pooling; 分类头使用 dropout、128 维全连接层、ReLU、dropout 与三分类输出层。CNN 训练 5 个 epoch, batch size 为 256, 优化器为 AdamW, 学习率  $1 \times 10^{-3}$ , weight decay 为  $1 \times 10^{-4}$ , 损失函数为带类别权重的 cross entropy。训练过程按 validation Macro-F1 选择并保存最佳 epoch; seed=42 的最佳 epoch 为第 5 轮。需要说明的是, CNN 训练含 GPU 非确定性算子, 固定种子也不能保证逐位复现, 因此本文对 CNN 报告多种子统计量 (见本节下文)。

RNA-FM/RNABERT 路线使用本地权重加载 multimolecule 模型, 将 DNA 序列中的 T 转换为 U 后输入 tokenizer, 冻结 encoder 并对 last hidden states 进行

attention-mask mean pooling。pooled embedding 与 engineered splice signal 特征拼接后输入 scikit-learn LogisticRegression，其中 `class_weight="balanced"`、`solver="lbfgs"`、`C=1.5`、`max_iter=1200`。实验三的变异效应分数由同一三分类模型对 WT/Mut 序列的 donor/acceptor/non-splice 概率变化计算得到。本文主表（表 3-1、4-1、5-2 与 5-3）中可训练模型的指标均以 42/43/44 三个种子的  $\text{mean} \pm \text{std}$  报告，多种子汇总写入 `results/experiment_1/tables/experiment_1_multiseed_summary.csv`、`results/experiment_2/tables/experiment_2_multiseed_summary.csv` 与 `results/experiment_3/tables/experiment_3_multiseed_summary.csv`。RNA-FM/RNABERT 为确定性 frozen-encoder + LogisticRegression，三个种子标准差为 0；SpliceAI、Pangolin、MMSplice、MaxEntScan 为确定性单次推理，不含种子方差。实验一 CNN 的 Macro-F1 为  $0.827 \pm 0.012$ 。

## 2.5 评估指标

三分类任务：评估 Accuracy、Macro-F1、macro one-vs-rest AUROC 和 macro one-vs-rest AUPRC，并单独统计 hard-negative FPR（hard-negative FPR 的分母限定为测试集中 `label == 2` 且 `negative_type` 包含 `hard` 的样本）。若将 splice-site positive 与 non-splice negative 合并为二分类，数据全量 positive base rate 为  $2000/3000 = 0.667$ ；本文表中的多分类 AUPRC 是 macro one-vs-rest 指标。

变异效应任务：将 ClinVar splice-altering 与 neutral 作为二分类排序问题，主表评估 AUROC 与 AUPRC。ClinVar benchmark 为 250/250 balanced，因此 AUPRC 随机基准为 0.5。本文同时报告 exact-distance-matched 子集上的 AUROC/AUPRC，用于诊断模型是否主要利用“距离剪接位点更近”这一捷径。

## 第三章 实验一：剪接位点三分类

### 3.1 实验设计

实验一将序列分为 donor、acceptor 和 non-splice 三类，建立上下文分析和变异效应预测的基础分类器。

模型类别包括 CNN baseline、RNA-FM frozen encoder + MLP 和 RNABERT frozen encoder + MLP。RNA-FM/RNABERT 均使用本地权重。

训练使用 2339 条样本，验证使用 230 条样本，测试使用 431 条样本。

### 3.2 结果

表 3-1 展示测试集结果，与基线进行对比。

CNN baseline 与 RNABERT frozen encoder + MLP 的 Macro-F1 接近，三个种子均值分别为  $0.827 \pm 0.012$  和  $0.820 \pm 0.000$ ，而 RNA-FM frozen encoder + MLP 的 Macro-F1 为  $0.767 \pm 0.000$ ，低于另外两类模型。然而三类模型在真实 GT/AG hard-negative 上的 FPR 仍处于约三成上下的水平（多种子均值约 0.26–0.35；CNN  $0.348 \pm 0.034$ 、RNA-FM 0.329、RNABERT 0.323），说明仅凭当前小样本训练仍难以完全拒绝真实 motif-matched decoy。

表 3-1 实验一测试集三分类结果（seed 42/43/44 的 mean  $\pm$  std）

| 模型                           | Accuracy                          | Macro-F1                          | AUROC                             | AUPRC                             | Hard FPR          |
|------------------------------|-----------------------------------|-----------------------------------|-----------------------------------|-----------------------------------|-------------------|
| CNN baseline                 | <b>0.828<math>\pm</math>0.013</b> | <b>0.827<math>\pm</math>0.012</b> | <b>0.950<math>\pm</math>0.001</b> | <b>0.907<math>\pm</math>0.001</b> | 0.348 $\pm$ 0.034 |
| RNA-FM frozen encoder + MLP  | 0.763 $\pm$ 0.000                 | 0.767 $\pm$ 0.000                 | 0.916 $\pm$ 0.000                 | 0.840 $\pm$ 0.000                 | 0.329 $\pm$ 0.000 |
| RNABERT frozen encoder + MLP | 0.819 $\pm$ 0.000                 | 0.820 $\pm$ 0.000                 | 0.930 $\pm$ 0.000                 | 0.872 $\pm$ 0.000                 | 0.323 $\pm$ 0.000 |

RNA-FM/RNABERT 为确定性 frozen encoder + LogisticRegression，三个种子标准差为 0；加粗为各“越高

越好”列的最优值。

这个结果回答了 RQ1：在真实 chromosome-holdout split 上，模型可以完成 donor/acceptor/non-splice 三分类，但真实 GT/AG hard-negative 仍然具有挑战性。CNN baseline 和 RNABERT frozen encoder + MLP 的总体 Macro-F1 接近；以 seed=42 为例，二者都将 155 条 hard-negative 中的 50 条误判为 splice-site，RNA-FM 为 51 条，而跨三个种子后 CNN 的 hard-negative FPR 均值为  $0.348 \pm 0.034$ 。由此可见，真实 motif-matched decoy 比 synthetic control 更难，当前模型尚不能简单依赖局部 GT/AG motif 之外的有限线索完全拒绝负例。




图 3-1 实验一各模型测试集 Macro-F1 对比。CNN baseline 与 RNABERT frozen encoder + MLP 在真实 chromosome-holdout split 上接近，需结合 hard-negative FPR 解读。




图 3-2 实验一各模型测试集混淆矩阵。主要应关注 non-splice 被误判为 donor/acceptor 的格子，因为这些错误对应 hard-negative 上的 motif 依赖问题。

### 3.3 小结

实验一说明，在小样本条件下，序列模型能够完成基础剪接位点识别，但三类模型在 GT/AG hard-negative 上仍有约三成上下（0.26–0.35）的误报，说明真实诱饵位点比简单 motif 匹配更难处理。

这个问题引出实验二：剪接识别是否需要更大范围的上下文证据？

## 第四章 实验二：多尺度上下文与困难负例

### 4.1 实验设计

实验二围绕三个问题展开：

第一，改变上下文窗口大小（pm50, pm100, pm200, pm400），观察模型性能是否随上下文变化。

第二，构造 GT/AG hard-negative，检验模型是否把局部 motif 误判为真实剪接位点。

第三，构造 rare motif 压力测试，观察真实模型对非经典中心二核苷酸改写的敏感性。

### 4.2 多尺度上下文结果

表 4-1 给出了不同窗口下的 Macro-F1 与 hard-negative FPR。

CNN baseline 在 pm50 上 Macro-F1 最高，为  $0.839 \pm 0.007$ ；RNABERT frozen encoder + MLP 在 pm400 上最高，为  $0.848 \pm 0.000$ ；RNA-FM 在各窗口上整体低于另外两类模型。真实数据上的窗口趋势并不单调，更长上下文不会自动改善所有模型。

hard-negative FPR 也呈非单调变化：RNABERT 在 pm400 上最低，为  $0.265 \pm 0.000$ ；RNA-FM 在 pm50 和 pm400 上较低，均值分别为 0.277 和 0.290；CNN baseline 的均值在 pm100/pm200/pm400 维持在 0.29–0.30，但跨种子标准差较大（如 pm400 为  $0.301 \pm 0.078$ ）。这说明上下文长度、模型表示和真实诱饵序列分布共同影响拒绝能力，且 CNN 在 hard-negative 上的稳定性弱于两类 frozen encoder。

表 4-1 实验二多尺度上下文结果 (seed 42/43/44 的 mean  $\pm$  std)

| flank | 模型                           | Macro-F1                          | Hard FPR          |
|-------|------------------------------|-----------------------------------|-------------------|
| 50    | CNN baseline                 | 0.839 $\pm$ 0.007                 | 0.258 $\pm$ 0.097 |
| 50    | RNA-FM frozen encoder + MLP  | 0.802 $\pm$ 0.000                 | 0.277 $\pm$ 0.000 |
| 50    | RNABERT frozen encoder + MLP | 0.814 $\pm$ 0.000                 | 0.310 $\pm$ 0.000 |
| 100   | CNN baseline                 | 0.819 $\pm$ 0.007                 | 0.286 $\pm$ 0.092 |
| 100   | RNA-FM frozen encoder + MLP  | 0.763 $\pm$ 0.000                 | 0.361 $\pm$ 0.000 |
| 100   | RNABERT frozen encoder + MLP | 0.832 $\pm$ 0.000                 | 0.290 $\pm$ 0.000 |
| 200   | CNN baseline                 | 0.829 $\pm$ 0.008                 | 0.297 $\pm$ 0.055 |
| 200   | RNA-FM frozen encoder + MLP  | 0.787 $\pm$ 0.000                 | 0.310 $\pm$ 0.000 |
| 200   | RNABERT frozen encoder + MLP | 0.815 $\pm$ 0.000                 | 0.329 $\pm$ 0.000 |
| 400   | CNN baseline                 | 0.824 $\pm$ 0.004                 | 0.301 $\pm$ 0.078 |
| 400   | RNA-FM frozen encoder + MLP  | 0.788 $\pm$ 0.000                 | 0.290 $\pm$ 0.000 |
| 400   | RNABERT frozen encoder + MLP | <b>0.848<math>\pm</math>0.000</b> | 0.265 $\pm$ 0.000 |

RNA-FM/RNABERT 为确定性 frozen encoder，三个种子标准差为 0；CNN 的 hard-negative FPR 跨种子方差较大。本表 pm200 行来自实验二多尺度训练，与表 3-1（实验一主线训练）为独立的 CNN 训练实例，叠加上述非确定性后，二者的 CNN pm200 hard-negative FPR 会略有差异。加粗为 Macro-F1 列的最优值。




图 4-1 实验二不同上下文窗口下的 Macro-F1 变化。真实 chromosome-holdout split 上曲线非单调，说明更长上下文不会自动改善所有模型。






图 4-2 实验二不同上下文窗口下的 AUPRC 变化。AUPRC 整体较高，但需要与 hard-negative FPR 一起解读，否则容易高估 motif-matched negative 上的鲁棒性。

### 4.3 Hard-negative 与 rare motif

在 pm200 的 155 条 hard-negative 测试样本上，三个种子（42/43/44）的 hard-negative FPR 均值为：

CNN baseline:  $0.297 \pm 0.055$ ;

RNA-FM frozen encoder + MLP:  $0.310 \pm 0.000$ ;

RNABERT frozen encoder + MLP:  $0.329 \pm 0.000$ 。

由于 hard-negative 分母只有 155 条，且 CNN 的跨种子标准差较大（0.055），三类模型的区间高度重叠。因此当前结果不支持“某一模型显著优于其他模型”的强结论；更稳健的结论是，真实 GT/AG hard-negative 对三类模型都构成压力。




图 4-3 实验二 hard-negative false positive rate 对比。真实主 benchmark 的 non-splice 全部为 GT/AG motif-matched hard-negative; 三类模型均存在约三成上下的误报。

Rare motif 分析进一步说明，模型对非经典 motif 的处理并不一致。

GC-AG donor 对 CNN 较容易，而对 RNA-FM/RNABERT frozen encoder 的分类结果更不稳定；AT-AC acceptor 对 RNA-FM 较容易，但对 CNN 和 RNABERT 更困难。这说明，局部 motif 类型、训练分布和模型表示都会影响小样本泛化。

表 4-2 实验二 rare motif 压力测试结果

| 模型                           | motif type          | rows | Accuracy | Macro-F1 |
|------------------------------|---------------------|------|----------|----------|
| CNN baseline                 | rare AT-AC acceptor | 40   | 0.100    | 0.091    |
| CNN baseline                 | rare GC-AG donor    | 40   | 1.000    | 1.000    |
| RNA-FM frozen encoder + MLP  | rare AT-AC acceptor | 40   | 0.100    | 0.061    |
| RNA-FM frozen encoder + MLP  | rare GC-AG donor    | 40   | 0.250    | 0.200    |
| RNABERT frozen encoder + MLP | rare AT-AC acceptor | 40   | 0.025    | 0.016    |
| RNABERT frozen encoder + MLP | rare GC-AG donor    | 40   | 0.725    | 0.420    |

每个 cell 仅 40 条 synthetic 样本，指标方差大，数值只用于定性比较。

这一现象也提示，rare motif case study 不应被解释为真实罕见剪接位点 benchmark。当前 rare motif 是在 synthetic 序列上替换中心二核苷酸得到的压力测试，

其价值在于暴露不同特征路线对 motif 改写的敏感性，而不是估计真实 GC-AG 或 AT-AC 剪接事件的总体召回率。

## 4.4 小结

实验二将实验一的分类结果推进到机制层面：局部 motif 是必要线索，但不能保证分类正确。

实验二主要由真实 GT/AG hard-negative 压力测试支撑。更准确地说，本文能支持的结论是：在真实基因组中，GT/AG motif 本身远非充分判据；当前小样本模型仍会在 motif-matched negative 上产生可观误报。Rare motif 仅作为 synthetic control，用于观察模型对非经典二核苷酸改写的敏感性。

## 第五章 实验三：异常剪接变异效应预测

### 5.1 实验设计

实验三将剪接识别信号转化为真实 ClinVar SNV 的变异效应排序任务。主数据集为 `data/experiment_3/clinvar_splicing_variants.csv`，包含 250 条 splice-altering 变异和 250 条 benign/likely benign near-splice 变异。所有变异均限制在 held-out test chromosomes，并排除实验一/二已经采样的 genes。

表 5-1 给出变异类型分布。这里不再使用人工 donor gain/loss 或 acceptor gain/loss 作为主结论，而是按真实 ClinVar 标签和最近 donor/acceptor target 进行分层。

表 5-1 实验三真实 ClinVar 变异集组成

| variant type            | label           | rows |
|-------------------------|-----------------|------|
| acceptor ClinVar splice | splice-altering | 141  |
| donor ClinVar splice    | splice-altering | 109  |
| ClinVar benign SNV      | neutral         | 250  |

对每个变异，项目内三分类模型分别对 WT 与 Mut 序列计算 donor/acceptor/non-splice 概率，并用目标剪接类别概率变化构造 impact score。SpliceAI、Pangolin、MMSplice 与 MaxEntScan 则通过真实工具接口计算 WT/Mut 成对 delta score。由于 ClinVar 正负样本平衡为 250/250，本实验 AUPRC 随机基准为 0.5。

### 5.2 ClinVar 排序结果

表 5-2 显示 full ClinVar benchmark 上的排序结果。RNA-FM frozen encoder + MLP 取得最高 AUROC  $0.753 \pm 0.000$  和 AUPRC  $0.784 \pm 0.000$ ；Pangolin real sequence model（确定性单次）与 CNN baseline 分别达到 AUROC 0.702 和  $0.689 \pm 0.012$ ；MMSplice 当前输出在该集上为常数型分数，AUROC/AUPRC 均为 0.5，

等价于随机排序。

表 5-2 实验三真实 ClinVar 变异效应预测结果（项目模型为 seed 42/43/44 的 mean  $\pm$  std）

| 模型                           | AUROC                             | AUPRC                             |
|------------------------------|-----------------------------------|-----------------------------------|
| RNA-FM frozen encoder + MLP  | <b>0.753<math>\pm</math>0.000</b> | <b>0.784<math>\pm</math>0.000</b> |
| Pangolin real sequence model | 0.702                             | 0.778                             |
| CNN baseline                 | 0.689 $\pm$ 0.012                 | 0.738 $\pm$ 0.005                 |
| RNABERT frozen encoder + MLP | 0.667 $\pm$ 0.000                 | 0.733 $\pm$ 0.000                 |
| SpliceAI real sequence model | 0.643                             | 0.729                             |
| MaxEntScan real local score  | 0.617                             | 0.672                             |
| MMSplice real sequence model | 0.500                             | 0.500                             |

项目模型（CNN/RNA-FM/RNABERT）报告三个种子的 mean  $\pm$  std；SpliceAI、Pangolin、MMSplice、MaxEntScan 为确定性单次推理，不含种子方差。加粗为各列最优值。

这一排序不应被解读为“项目内模型整体优于成熟工具”。更合理的解释是：当前 ClinVar benchmark 被限制在近剪接位点 SNV，且 pathogenic/splice-altering 变异距离注释剪接位点更近。项目内模型与 MaxEntScan 更容易利用局部 motif 和距离相关线索；真实外部工具则依赖更复杂的真实基因组上下文、转录本注释和工具内部校准。因此，实验三同时报告 distance-matched 子集，用于检验模型是否主要利用距离捷径。




图 5-1 实验三真实 ClinVar 变异效应预测 AUROC 对比。虚线表示随机排序基准 AUROC = 0.5。




图 5-2 实验三真实 ClinVar 变异效应预测 AUPRC 对比。由于 ClinVar benchmark 为 250/250 balanced，虚线 AUPRC = 0.5 表示随机排序基准。




图 5-3 实验三各模型在 splice-altering 与 neutral 两类 ClinVar 变异上的 delta/impact score 分布。两类分数的分离程度直观反映了排序能力；分布重叠越大，对应 AUROC/AUPRC 越接近随机。

### 5.3 距离匹配诊断与分类型响应

QC 显示 full ClinVar 中 splice-altering 变异的 median distance 为 9.5 bp, neutral 变异为 17 bp; distance-only baseline 已达到 AUROC 0.6475 和 AUPRC 0.6917。因此，表 5-3 报告 exact-distance-matched 子集上的结果。该子集包含 326 条变异，正负样本 163/163，distance-only AUROC/AUPRC 均为 0.5。

表 5-3 实验三 exact-distance-matched ClinVar 子集结果 (项目模型为 seed 42/43/44 的 mean  $\pm$  std)

| 模型                           | AUROC                             | AUPRC                             |
|------------------------------|-----------------------------------|-----------------------------------|
| RNA-FM frozen encoder + MLP  | <b>0.668<math>\pm</math>0.000</b> | <b>0.656<math>\pm</math>0.000</b> |
| Pangolin real sequence model | 0.590                             | 0.642                             |
| SpliceAI real sequence model | 0.513                             | 0.569                             |
| CNN baseline                 | 0.546 $\pm$ 0.020                 | 0.563 $\pm$ 0.009                 |
| MaxEntScan real local score  | 0.467                             | 0.550                             |
| RNABERT frozen encoder + MLP | 0.515 $\pm$ 0.000                 | 0.544 $\pm$ 0.000                 |
| MMSplice real sequence model | 0.500                             | 0.500                             |

行按 AUPRC 排序；项目模型报告三个种子的 mean  $\pm$  std，外部工具为确定性单次推理。加粗为各列最优值。

与 full ClinVar 相比，distance-matched 后多数模型 AUROC/AUPRC 明显下降。RNA-FM 仍保留一定区分度，但 AUROC 从 0.753 降至 0.668；Pangolin 从 0.702 降至 0.590；CNN 从 0.689 降至 0.546；SpliceAI 接近随机。这说明 full benchmark 的一部分可分性来自距离混杂，真实变异效应评估必须同时报告匹配子集或其他去混杂诊断。




图 5-4 实验三不同 ClinVar 变异类型下的平均 impact score。acceptor/donor ClinVar splice 变异整体高于 benign SNV，但不同模型对 donor 与 acceptor target 的响应强度并不完全一致。

## 5.4 可解释性分析

实验三的解释性分析对 donor、acceptor 和 hard-negative 三类 case 都做了 in-silico mutagenesis（完整矩阵见 results/experiment\_3/tables/），并对真实 ClinVar case 计算 WT/Mut delta profile。该分析将标量 impact score 投影回序列位置，用于观察变异附近剪接信号如何变化。下文以 donor case 的 ISM 热图（图 5-6）为例展示，acceptor 与 hard-negative 的矩阵格式相同。需要强调的是，这些图件用于解释当前模型响应，不代表临床风险校准。




图 5-5 实验三 impact score 分箱响应曲线。曲线基于真实 ClinVar 标签和当前模型 delta score 生成；高分箱 positive rate 上升说明分数具有排序价值，但仍需结合 distance-matched 结果理解。




图 5-6 donor case 的 in-silico mutagenesis 热图。横轴为相对位置，颜色表示替换碱基后的目标类别概率变化。






图 5-7 真实 ClinVar case 的 WT/Mut 剪接信号 delta profile。该图展示真实变异如何进入解释性流程，并用于定位模型分数变化对应的序列区域。

## 5.5 小结

实验三完成了从剪接识别到真实 ClinVar 变异效应排序的进一步深入，并加入了 SpliceAI、Pangolin、MMSplice 与 MaxEntScan 的工具推理结果。Full ClinVar 上 RNA-FM frozen encoder + MLP 排名最高，但 distance-matched 子集上的整体下降说明近剪接距离是重要混杂因素。因此，本文能支持的是“当前流程可在真实 ClinVar 小样本上形成可解释排序诊断”，而不是“完成了临床级变异泛化 benchmark”。

## 第六章 讨论

### 6.1 三个实验之间的逻辑关系

本文的三个实验构建了一条递进链路。实验一在真实 GENCODE/GRCh38 数据上建立 donor、acceptor 与 GT/AG hard-negative 三分类；实验二检验上下文窗口和 hard-negative 对模型的压力；实验三将识别信号转化为真实 ClinVar pathogenic-vs-benign 排序，并用 distance-matched 子集诊断混杂。

若没有实验二，实验一的总体 Macro-F1 可能掩盖 motif-matched negative 上的误报；若没有实验三，剪接识别只能停留在分类任务，无法连接到变异解释。三个实验合在一起，使本文从“能否识别剪接位点”推进到“这种识别是否可用于真实变异排序，以及边界在哪里”。

### 6.2 关键现象解释

第一，真实 GT/AG hard-negative 是比总体 Accuracy 更敏感的诊断指标。当前 non-splice 样本全部携带 GT/AG decoy 且不落在 GTF 注释剪接位点上，因此模型不能通过短 motif 查找解决任务。实验一和实验二中三类模型仍有约三成上下（0.26–0.35）的 hard-negative FPR，说明小样本条件下真实诱饵位点仍难以完全拒绝。

第二，上下文窗口的作用是非单调的。更长窗口可能提供更多调控信息，也可能引入更多噪声和分布差异。实验二中 RNABERT 在 pm400 上表现最好，但 CNN 在 pm50 上 Macro-F1 更高；因此本文不把“上下文越长越好”作为结论，而只说明上下文尺度需要和模型表示、样本规模共同评估。

第三，变异效应排序必须处理距离混杂。ClinVar splice-altering 变异更靠近注释剪接位点，这既符合生物学直觉，也会使模型通过“越近越可能致病”获得较高分数。Full ClinVar 和 exact-distance-matched 子集之间的差异说明，真实小样本 benchmark 中仅报告一个 AUROC/AUPRC 是不够的。

第四，外部工具的结果不能简单排行成“谁更强”。SpliceAI、Pangolin、MM-Splice 和 MaxEntScan 的输入假设、输出量纲与训练目标并不相同；本文只是把它们作为真实工具参照接入同一 ClinVar 小样本排序流程。MMSplice 在当前表上输出常数型分数，说明该集成或输入设置没有提供有效区分度，应作为负结果如实报告，而不是过度解释。

### 6.3 限制

首先，splice-site 数据只有 3000 条，ClinVar 只有 500 条，本文已对实验一、实验二 CNN 多尺度和实验三 CNN ClinVar 排序补充 42/43/44 三个随机种子汇总，但 RNA-FM/RNABERT 和外部工具仍以确定性单次推理为主。其次，当前 split 采用 chromosome holdout，并检查 gene overlap；QC 进一步完成了跨 split 完整窗口重复、中心 161 bp 重复和高 9-mer Jaccard 近重复审计，但这仍不能替代 BLAST/CD-HIT/MMseqs 等 alignment-level paralog clustering。第三，ClinVar benchmark 限于 near-splice SNV，不覆盖 indel、深内含子变异、结构变异或组织特异性剪接事件。第四，distance-matched 子集只能诊断并部分缓解距离混杂，不能替代更大规模、严格匹配的临床 benchmark。

后续工作可扩展到更大规模 GENCODE/ClinVar/SpliceVarDB 数据、同源聚类去重、更多随机种子、更多协变量匹配或回归调整，以及真实 GTEx/sQTL 表达数据<sup>[10]</sup>。只有在这些条件满足后，才适合讨论全基因组泛化、组织特异性剪接或临床级变异解释能力。

## 第七章 结论

本项目构建了真实序列分类、机制压力测试和 ClinVar 变异解释的完整链路。

三个实验共同说明：

第一，在真实 GENCODE/GRCh38 小样本条件下，可以建立 donor、acceptor、GT/AG hard-negative 三分类模型，但真实 motif-matched negative 仍会带来约三成上下（0.26–0.35）的误报；

第二，多尺度上下文分析表明，窗口长度对模型表现有影响但并非单调，hard-negative FPR 比总体 Macro-F1 更能揭示 motif 依赖；

第三，剪接识别信号可以转化为真实 ClinVar splice-altering vs benign 排序，full ClinVar 上 RNA-FM frozen encoder + MLP 表现最好，但 distance-matched 子集上的下降说明距离混杂必须被显式报告。

本文能够支持的核心结论是：真实 GT/AG hard-negative 是有效压力测试；真实小样本 ClinVar benchmark 可以用于变异效应排序诊断；distance-matched 分析能揭示近剪接距离捷径。本文不能支持的结论是：当前结果代表全基因组泛化、临床级变异解释、组织特异性剪接建模，或 alignment-level paralog/homology 去重后的稳健性能。

## 参考文献

- [1] BLACK D L. Mechanisms of Alternative Pre-Messenger RNA Splicing[J]. Annual Review of Biochemistry, 2003, 72: 291-336. DOI: 10.1146/annurev.biochem.72.121801.161720.
- [2] YEO G, BURGE C B. Maximum Entropy Modeling of Short Sequence Motifs with Applications to RNA Splicing Signals[J]. Journal of Computational Biology, 2004, 11(2-3): 377-394. DOI: 10.1089/1066527041410418.
- [3] JAGANATHAN K, KYRIAZOPOULOU PANAGIOTOPOULOU S, MCRAE J F, et al. Predicting Splicing from Primary Sequence with Deep Learning[J]. Cell, 2019, 176(3): 535-548.e24. DOI: 10.1016/j.cell.2018.12.015.
- [4] ZENG T, LI Y I. Predicting RNA Splicing from DNA Sequence Using Pangolin[J]. Genome Biology, 2022, 23: 103. DOI: 10.1186/s13059-022-02664-4.
- [5] CHENG J, NGUYEN T Y D, CYGAN K J, et al. MMSplice: Modular Modeling Improves the Predictions of Genetic Variant Effects on Splicing[J]. Genome Biology, 2019, 20: 48. DOI: 10.1186/s13059-019-1653-z.
- [6] CHEN J, HU Z, SUN S, et al. Interpretable RNA Foundation Model from Unannotated Data for Highly Accurate RNA Structure and Function Predictions[J]. ArXiv preprint arXiv:2204.00300, 2022. arXiv: 2204.00300.
- [7] AKIYAMA M, SAKAKIBARA Y. Informative RNA Base Embedding for RNA Structural Alignment and Clustering by Deep Representation Learning[J]. NAR Genomics and Bioinformatics, 2022, 4(1): lqac012. DOI: 10.1093/nargab/lqac012.

- [8] FRANKISH A, DIEKHANS M, FERREIRA A M, et al. GENCODE Reference Annotation for the Human and Mouse Genomes[J]. Nucleic Acids Research, 2019, 47(D1): D766-D773. DOI: 10.1093/nar/gky955.
- [9] LANDRUM M J, LEE J M, BENSON M, et al. ClinVar: Improving Access to Variant Interpretations and Supporting Evidence[J]. Nucleic Acids Research, 2018, 46(D1): D1062-D1067. DOI: 10.1093/nar/gkx1153.
- [10] GTEx Consortium. The GTEx Consortium Atlas of Genetic Regulatory Effects across Human Tissues[J]. Science, 2020, 369(6509): 1318-1330. DOI: 10.1126/science.aaz1776.
- [11] Course Project Team. Project Experiment 1 Classification Outputs[Z]. Local files: reports/experiment<sub>1</sub>.md and results/experiment<sub>1</sub>/. 2026.
- [12] Course Project Team. Project Experiment 2 Multiscale Context Outputs[Z]. Local files: reports/experiment<sub>2</sub>.md and results/experiment<sub>2</sub>/. 2026.
- [13] Course Project Team. Project Experiment 3 ClinVar Variant-Effect Outputs[Z]. Local files: reports/experiment<sub>3</sub>.md and results/experiment<sub>3</sub>/. 2026.
- [14] Course Project Team. Project Data Quality-Control Report[Z]. Local file: reports/data<sub>q.c</sub>.md. 2026.
- [15] Course Project Team. Project Model Boundary and Resource Notes[Z]. Local benchmark model and tool integration notes. 2026.

## 致 谢

感谢计算生物学课程提供的项目背景与实验要求。感谢 NJUThesis 模板维护者提供的论文排版框架。本项目所有主实验结果均来自经过处理的小样本数据、脚本和报告。

## 附录 A 数据、代码与结果路径

### A.1 数据路径

- 主 split: data/shared/splits/train.csv、data/shared/splits/valid.csv、data/shared/splits/test.csv。
- 多尺度窗口: data/shared/processed/splice\_sites\_pm50.csv、splice\_sites\_pm100.csv、splice\_sites\_pm200.csv、splice\_sites\_pm400.csv。
- 变异数据: data/experiment\_3/clinvar\_splicing\_variants.csv、data/experiment\_3/clinvar\_splicing\_variants\_distance\_matched.csv。

### A.2 代码路径

- 数据构建与 QC: src/data/build\_splice\_site\_dataset.py、src/data/build\_clinvar\_variant\_dataset.py、src/data/qc\_splice\_dataset.py。
- 实验一: src/experiments/exp1/run\_classification.py。
- 实验二: src/experiments/exp2/run\_multiscale.py。
- 实验三: src/experiments/exp3/run\_variant\_effect.py 与 src/experiments/exp3/run\_interpretability.py。

### A.3 结果与报告路径

- 实验结果: results/experiment\_1/、results/experiment\_2/、results/experiment\_3/。
- 中文实验报告: reports/experiment\_1.md、reports/experiment\_2.md、reports/experiment\_3.md。
- 数据质控报告: reports/data\_qc.md。



## A.4 复现命令

- 构建 splice-site 数据: `python -m src.data.build_splice_site_dataset -max-per-class 1000 --windows 50 100 200 400`。
- 构建 ClinVar 数据: `python -m src.data.build_clinvar_variant_dataset`。
- 数据 QC: `python -m src.data.qc_splice_dataset`。
- 实验一: `python -m src.experiments.exp1.run_classification --full-data`。
- 实验二: `python -m src.experiments.exp2.run_multiscale`。
- 实验三: `python -m src.experiments.exp3.run_variant_effect`。
- 解释性分析: `python -m src.experiments.exp3.run_interpretability`。

## A.5 实验三 Top-k 补充指标

表 A-1 保留实验三 full ClinVar benchmark 的 Top-k recall 与 enrichment。这里  $k = 50$ ，即 500 条 ClinVar 变异的前 10%。由于该指标对并列分数和极高分样本较敏感，主文仍主要依据 AUROC、AUPRC 和 distance-matched 诊断。

表 A-1 实验三 Top-k 补充指标

| 模型                           | Top-k recall | Enrichment |
|------------------------------|--------------|------------|
| RNA-FM frozen encoder + MLP  | 0.1960       | 1.9600     |
| Pangolin real sequence model | 0.1960       | 1.9600     |
| CNN baseline                 | 0.1960       | 1.9600     |
| RNABERT frozen encoder + MLP | 0.1960       | 1.9600     |
| SpliceAI real sequence model | 0.2000       | 2.0000     |
| MaxEntScan real local score  | 0.1960       | 1.9600     |
| MMSplice real sequence model | 0.0760       | 0.7600     |